

**UFERN**

**metrópole**  
DIGITAL

# Aprendizado por Reforço

Aproximação estocástica – parte 2

# Descida do Gradiente Estocástico

- Os algoritmos de descida do gradiente estocástico (SGD – do inglês *stochastic gradient descent*) são amplamente utilizados em aprendizado de máquina.
- Estimativa da média  $\rightarrow$  caso especial do SGD  $\rightarrow$  caso especial do RM.
- Considere o problema de otimização

$$\min_w J(w), \quad J(w) = \mathbb{E}_X[f(w, X)]$$

- $w$ : parâmetro a ser otimizado
- $X$ : variável aleatória
- $f(\cdot)$ : escalar

# Descida do Gradiente Estocástico

- Solução: algoritmo da descida do gradiente (GD – do inglês *gradient descent*)

$$w_{k+1} = w_k - \alpha_k \nabla_w J(w_k)$$

$$J(w) = \mathbb{E}_X[f(w, X)] \rightarrow \nabla_w J(w) = \nabla_w \mathbb{E}_X[f(w, X)] = \mathbb{E}_X[\nabla_w f(w, X)]$$

$$\boxed{w_{k+1} = w_k - \alpha_k \mathbb{E}_X[\nabla_w f(w_k, X)]}$$

- O GD exige  $\mathbb{E}_X[\nabla_w f(w, X)]$ . (**Como calcular?**)

# Descida do Gradiente Estocástico

- O cálculo de  $\mathbb{E}_X[\nabla_w f(w, X)]$  pode ser feito:
  1. Utilizando a distribuição de  $X$ , mas ela é **desconhecida** na prática.
  2. Utilizando  $n$  amostras i.i.d. de  $X$  e fazer uso da aproximação:

$$\mathbb{E}_X[\nabla_w f(w, X)] \approx \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i)$$

E dessa forma

$$w_{k+1} = w_k - \alpha_k \left( \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i) \right)$$

- **Qual o problema da formulação acima?**

# Descida do Gradiente Estocástico

- Problema

- Requer todas as amostras por iteração.

- Solução

- Descida do gradiente estocástico (SGD) → atualização de  $w$  a cada amostra  $x$ .

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

- GD vs. SGD

- GD: gradiente verdadeiro  $\mathbb{E}_X[\nabla_w f(w_k, X)]$ .
  - SGD: gradiente estocástico  $\nabla_w f(w_k, x_k)$ .
    - **Ainda podemos assegurar que  $w_k \rightarrow w^*$  quando  $k \rightarrow \infty$ ?**

# Descida do Gradiente Estocástico

- Observe que:

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w_k, X)] + \underbrace{(\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)])}_{\eta_k}$$
$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w_k, X)] + \eta_k$$

# Descida do Gradiente Estocástico

- O algoritmo do SGD pode ser reescrito como:

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

$$w_{k+1} = w_k - \alpha_k (\mathbb{E}[\nabla_w f(w_k, X)] + \eta_k)$$

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)] - \alpha_k \eta_k$$

- Fórmula é idêntica ao GD + um termo de perturbação.

# Descida do Gradiente Estocástico

- $\eta_k$  tem média zero  $\rightarrow$  intuitivamente indica que pode não comprometer a convergência.

$$\mathbb{E}[\eta_k] = \mathbb{E}[\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]]$$

$$\mathbb{E}[\eta_k] = \mathbb{E}[\nabla_w f(w_k, x_k)] - \mathbb{E}[\mathbb{E}[\nabla_w f(w_k, X)]]$$

$$\mathbb{E}[\eta_k] = \mathbb{E}_{x_k}[\nabla_w f(w_k, x_k)] - \mathbb{E}_X[\nabla_w f(w_k, X)]$$

$$\mathbb{E}[\eta_k] = \mathbb{E}_X[\nabla_w f(w_k, x_k)] - \mathbb{E}_X[\nabla_w f(w_k, X)]$$

$$\boxed{\mathbb{E}[\eta_k] = 0}$$



# Descida do Gradiente Estocástico

- Problema de estimação da Média como um problema de otimização

$$\min_w J(w), \quad J(w) = \mathbb{E}[f(w, X)]$$

- $f(w, X) = \frac{1}{2} \|w - X\|^2$
- $\nabla_w f(w_k, X) = w - X$
- A solução ótima para  $\nabla_w J(w) = 0$  é  $w^* = \mathbb{E}[X]$ .

# Descida do Gradiente Estocástico

- Problema de estimação da Média como um problema de otimização
  - Algoritmo GD

$$w_{k+1} = w_k - \alpha_k \nabla_w J(w)$$

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[w_k - X]$$

Não aplicável pois  
 $\mathbb{E}[X]$  é desconhecido.

- Algoritmo SGD

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

$$w_{k+1} = w_k - \alpha_k (w_k - x_k)$$

- Estimativa da média incremental  $\rightarrow$  caso especial do SGD, isto é, um SGD projetado para estimar a média.

# Descida do Gradiente Estocástico

- Padrão de convergência do SGD

- Erro relativo:

$$\delta_k = \frac{|\nabla_w f(w, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}$$

- Longe de  $w^*$ : trajetória se comporta com GD → convergência rápida.
  - Perto de  $w^*$ : convergência mais aleatória.

# Descida do Gradiente Estocástico

- Exemplo: Estimativa da Média

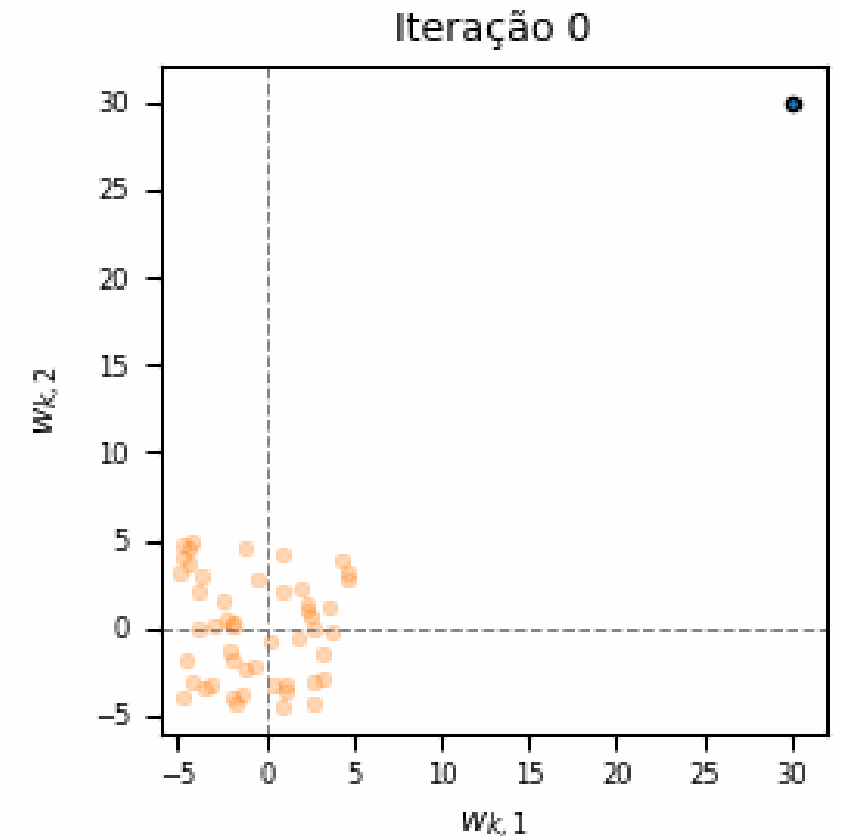
$$\min_w J(w) = \mathbb{E} \left[ \frac{1}{2} \|w - X\|^2 \right] = \mathbb{E}[f(w, X)]$$

- $\nabla_w f(w, x_k) = w - x_k$
- $\mathbb{E}[\nabla_w f(w, X)] = \mathbb{E}[w - X] = w - \mathbb{E}[X] = w - w^*$

- Erro relativo ( $\delta_k$ ):

$$\delta_k = \frac{|\nabla_w f(w, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|} = \frac{|(w - x_k) - (w - \mathbb{E}[X])|}{|w - w^*|} = \frac{|\mathbb{E}[X] - x_k|}{|w - w^*|}$$

- $w_k$  longe de  $w^*$ : erro pequeno  $\rightarrow$  SGD  $\approx$  GD (rápido).
- $w_k$  perto de  $w^*$ : erro pode ser maior  $\rightarrow$  trajetória mais aleatória.
- $\mathbb{E}[\delta_k] \propto \text{Var}[X]$



# Descida do Gradiente Estocástico

- Formulação determinística do SGD
  - Considere o conjunto  $\{x_i\}_{i=1}^n$  (não necessariamente amostras de uma variável aleatória).
  - Problema otimização

$$\min_w J(w), \quad J(w) = \frac{1}{n} \sum_{i=1}^n f(w, x_i)$$

- $f(w, x_i)$ : função parametrizada por  $w$
- $w$ : parâmetro a ser otimizado

# Descida do Gradiente Estocástico

- Formulação determinística do SGD

- Algoritmo GD

$$w_{k+1} = w_k - \alpha_k \nabla_w J(w_k) = w_k - \alpha_k \left( \frac{1}{n} \sum_{i=1}^n \nabla_w f(w, x_i) \right)$$

- Formulação incremental (se  $n$  é grande)

$$w_{k+1} = w_k - \alpha_k \nabla_w J(w_k) = w_k - \alpha_k \nabla_w f(w, x_k)$$

- $x_k$ : elemento obtido no tempo  $k$  (não necessariamente o  $k$ -ésimo elemento).
    - **O algoritmo incremental acima é SGD?**
    - **Como usar o conjunto finito  $\{x_i\}_{i=1}^n$ ? Usar na ordem ou amostrar aleatoriamente?**
  - **Como podemos converter a formulação determinística em uma formulação estocástica?**

# Descida do Gradiente Estocástico

- Conversão: formulação determinística  $\rightarrow$  formulação estocástica
  - Introdução de uma variável aleatória  $X$  definida sobre  $\{x_i\}_{i=1}^n$  com distribuição uniforme:

$$p(X = x_i) = \frac{1}{n}$$

- Novo problema otimização

$$\min_w J(w), \quad J(w) = \frac{1}{n} \sum_{i=1}^n f(w, x_i) = \mathbb{E}[f(w, X)]$$

- O algoritmo  $w_{k+1} = w_k - \alpha_k \nabla_w f(w, x_k)$  é SGD se  $x_k$  for amostrado uniformemente e independentemente  $\{x_i\}_{i=1}^n$  (o mesmo elemento pode ser repetido na amostragem).

# Descida do Gradiente Estocástico

- Batch GD, SGD e Mini-batch GD
  - Problema de otimização

$$\min_w J(w), \quad J(w) = \mathbb{E}[f(w, X)]$$

- Dado o conjunto de amostras  $\{x_i\}_{i=1}^n$  da variável aleatória  $X$ .



# Descida do Gradiente Estocástico

- Batch GD, SGD e Mini-batch GD

- Batch GD (BGD): usa todas as  $n$  amostras por iteração.

$$w_{k+1} = w_k - \alpha_k \left( \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i) \right)$$

- Mini-batch GD (MBGD): usa  $m$  amostras por iteração ( $m < n$ ).

$$w_{k+1} = w_k - \alpha_k \left( \frac{1}{m} \sum_{j \in J_k} \nabla_w f(w_k, x_j) \right), \quad J_k \subseteq \{1, \dots, n\}, \quad |J_k| = m$$

- SGD: usa 1 amostra por iteração.

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

# Descida do Gradiente Estocástico

- MBGD

- Versão intermediária entre SGD e BGD.
- Menos aleatório que SGD.
- Mais flexível que BGD por usar menos amostras.
- Se  $m = 1$ , então MBGD = SGD.
- Se  $m = n$ , então MBGD = BGD?

# Descida do Gradiente Estocástico

- MBGD

- Versão intermediária entre SGD e BGD.
- Menos aleatório que SGD.
- Mais flexível que BGD por usar menos amostras.
- Se  $m = 1$ , então MBGD = SGD.
- **Se  $m = n$ , então MBGD = BGD?**
  - Não necessariamente: MBGD usa amostras aleatórias, podendo repetir o mesmo elemento.
- Convergência geralmente mais rápida que SGD.

# Descida do Gradiente Estocástico

- Exemplo: Estimativa da Média

- Dado um conjunto  $\{x_i\}_{i=1}^n$ , temos o seguinte problema de otimização:

$$\min_w J(w), \quad J(w) = \frac{1}{2n} \sum_{i=1}^n \|w - x_i\|^2$$

- Solução ótima

$$w^* = \bar{x}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

# Descida do Gradiente Estocástico

- Algoritmos para estimar a média

- BGD:

$$w_{k+1} = w_k - \alpha_k \left( \frac{1}{n} \sum_{i=1}^n (w_k - x_i) \right) = w_k - \alpha_k (w_k - \bar{x})$$

- MBGD

$$w_{k+1} = w_k - \alpha_k \left( \frac{1}{m} \sum_{j \in \mathcal{J}_k} (w_k - x_j) \right) = w_k - \alpha_k (w_k - \bar{x}_k^{(m)}), \quad \bar{x}_k^{(m)} = \frac{1}{m} \sum_{j \in \mathcal{J}_k} x_j$$

- SGD:

$$w_{k+1} = w_k - \alpha_k (w_k - x_k)$$

# Descida do Gradiente Estocástico

- Algoritmos para estimar a média ( $\alpha_k = 1/k$ ):

- BGD:

$$w_{k+1} = \frac{1}{k} \sum_{j=1}^k \bar{x} = \bar{x}$$

- MBGD

$$w_{k+1} = \frac{1}{k} \sum_{j=1}^k \bar{x}_j^{(m)}$$

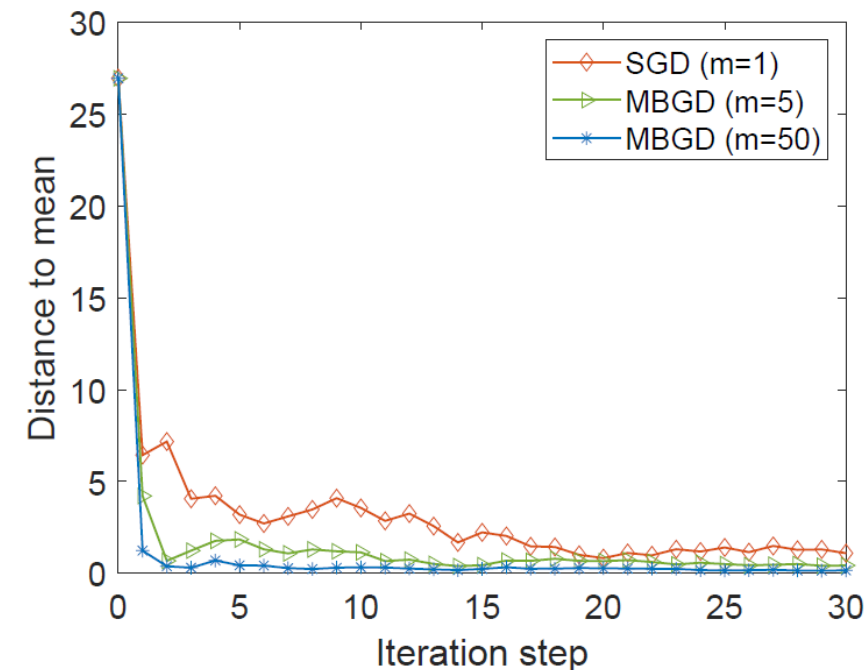
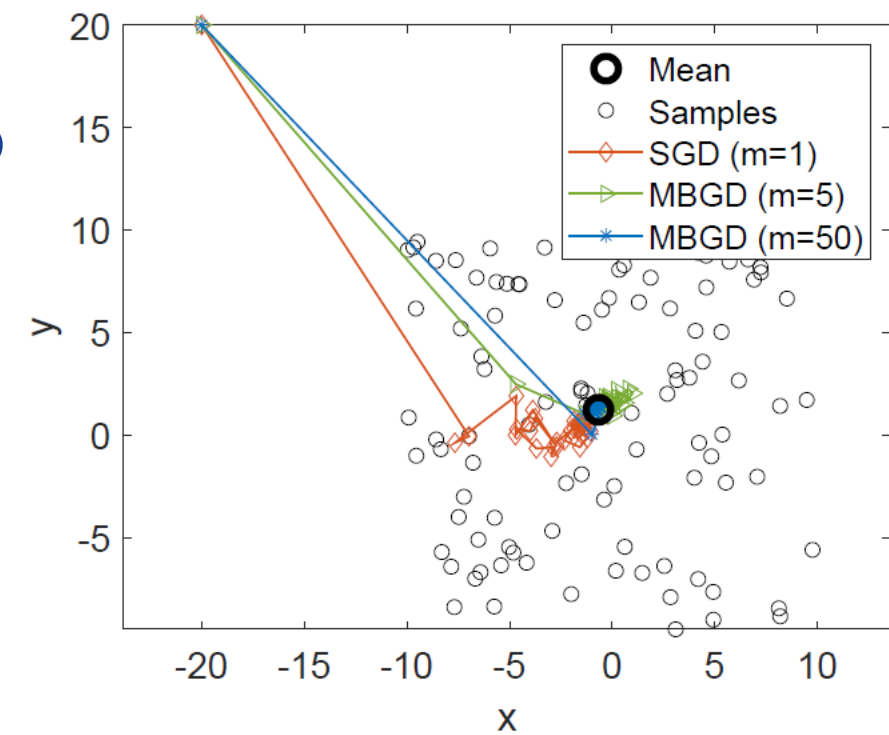
- SGD:

$$w_{k+1} = \frac{1}{k} \sum_{j=1}^k x_j$$

Observações:

BGD: convergência imediata.

MBGD: convergência mais rápida do que SGD.



# Revisão

- O que é aproximação estocástica?
- Por que precisamos estudar aproximação estocástica?
- Por que discutimos frequentemente o problema de estimação da média?
- Qual é a vantagem do algoritmo de RM sobre outros algoritmos para encontrar raízes?

- O que é aproximação estocástica?
  - Aproximação estocástica refere-se a uma ampla classe de algoritmos iterativos estocásticos para resolver problemas de encontrar raízes ou de otimização.
- Por que precisamos estudar aproximação estocástica?
  - Porque os algoritmos de aprendizado por reforço com diferença temporal podem ser vistos como algoritmos de aproximação estocástica.
- Por que discutimos frequentemente o problema de estimação da média?
  - Porque os valores de estado e de ação são definidos como médias de variáveis aleatórias. Os algoritmos de aprendizado por diferença temporal são semelhantes a algoritmos de aproximação estocástica para estimação de média.
- Qual é a vantagem do algoritmo de RM sobre outros algoritmos para encontrar raízes?
  - O algoritmo RM é poderoso no sentido de que não requer a expressão da função objetivo nem de sua derivada. Como resultado, é um método de caixa-preta que exige apenas a entrada e a saída da função objetivo. O famoso algoritmo SGD é uma forma especial do algoritmo de RM.



# Revisão

- Qual é a ideia básica do SGD?
- O SGD pode convergir rapidamente?
- O que é MBGD? Quais são suas vantagens em relação ao SGD e ao BGD?

- Qual é a ideia básica do SGD?
  - O SGD tem como objetivo resolver problemas de otimização que envolvem variáveis aleatórias. Quando as distribuições de probabilidade das variáveis aleatórias fornecidas não são conhecidas, o SGD pode resolver os problemas de otimização apenas utilizando amostras. Matematicamente, o algoritmo SGD pode ser obtido substituindo o gradiente verdadeiro — expresso como um valor esperado — no algoritmo de descida do gradiente, por um gradiente estocástico.
- O SGD pode convergir rapidamente?
  - Padrão de convergência do SGD:
    - Se a estimativa estiver longe da solução ótima, então o processo de convergência é rápido.
    - Se a estimativa estiver próxima da solução, a aleatoriedade do gradiente estocástico torna-se significativa, e a taxa de convergência diminui.
- O que é MBGD? Quais são suas vantagens em relação ao SGD e ao BGD?
  - O MBGD pode ser visto como uma versão intermediária entre o SGD e o BGD.
  - Vantagens:
    - MBGD vs. SGD: MBGD tem menos aleatoriedade, pois utiliza mais amostras ao invés de apenas uma.
    - MBGD vs. BGD: MBGD não exige o uso de todas as amostras, tornando-o mais flexível.

# Referências

- S. Zhao. *Mathematical Foundations of Reinforcement Learning*. Springer Singapore, 2025. [capítulo 6]
  - **disponível em:** <https://github.com/MathFoundationRL/Book-Mathematical-Foundation-of-Reinforcement-Learning>

Slides construídos com base nos livros supracitados, os quais estão disponibilizados publicamente pelos seus respectivos autores.